Desafio técnico

Intelligence & Analytics

Analista de Dados

mercado libre

Contexto do desafio

Você acabou de ingressar no Mercado Livre e recebeu a missão de reformular o relatório do Data Driven Index (DDI), um índice utilizado para medir o quanto as equipes são orientadas a dados. O material de apoio inclui:

- **Artigo que explica a lógica de cálculo do índice**
- **Exemplos do dashboard atual**

1. Informações por Site (País), Usuários e Classificações

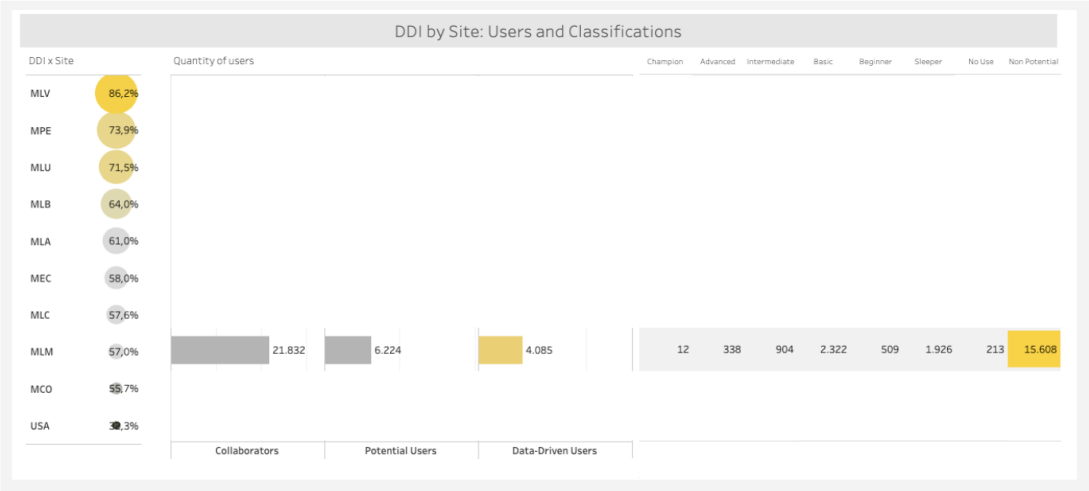

2. Detalhe de Site (País) por classificação e por divisão

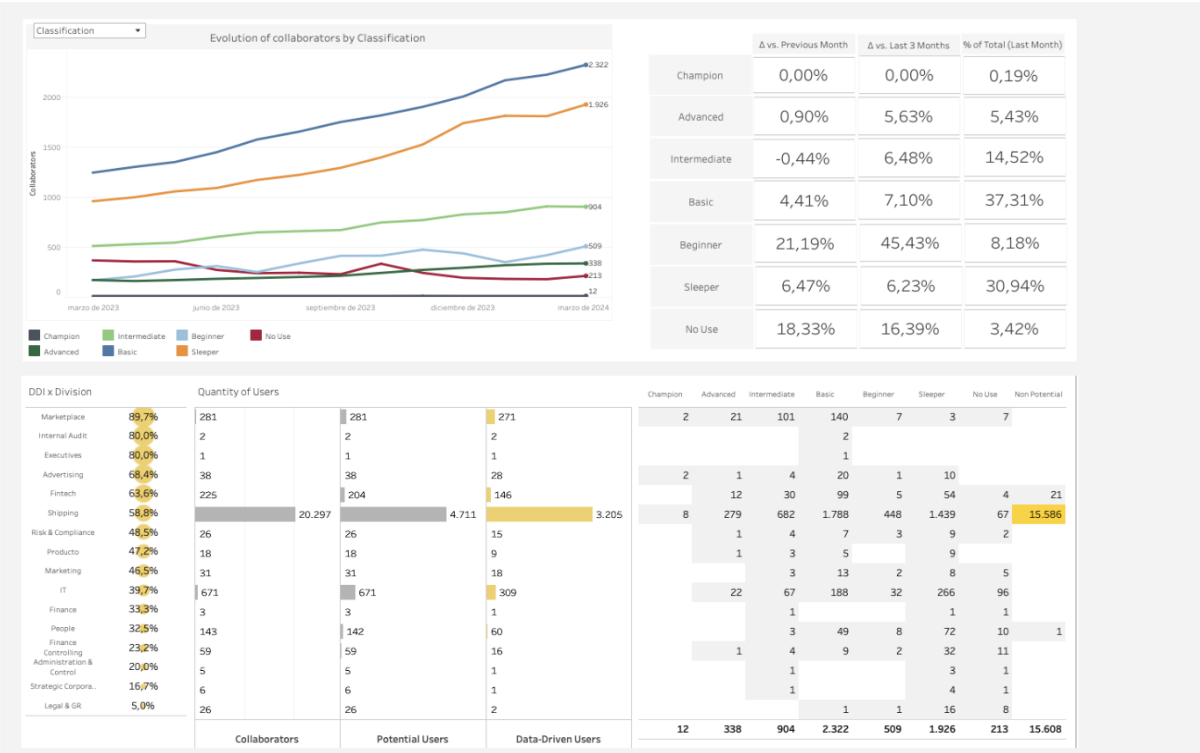

- **Exemplos das tabelas que alimentam o produto.**
- **Amostras de dados em formato CSV — tb_people_history.csv e tb_ddi.csv — com dados fictícios para o período janeiro–dezembro de 2025**

Considere que você tem 2 tabelas para trabalhar:

1. **tb_people_history:** tabela de registro histórico de colaboradores

campo	**descrição**	**tipo**
tim_day	data do registro da informação	date
username	identificador único do colaborador	string
start_date	data de início no Meli	date
end_date	data de saída do Meli	date
country	país	string
site	código do país (Ex: MLB = Brasil)	string
department	equipe	string
division	divisão (business unit)	string
function	função	string

2. **tb_ddi:** fotografia mensal do DDI por usuário

campo	**descrição**	**tipo**
username	identificador único do colaborador	string
date_month	mês de referência da informação	string
user_classification	classificação DDI do colaborador	string
is_data_user	flag de utilização de dados	boolean

Regras/observações do indicador

- O dashboard é atualizado e reportado mensalmente.
- Para o cálculo do DDI, considere apenas colaboradores ativos.
- "Usuários potenciais" são aqueles colaboradores que registram is_data_user = True durante 3 meses consecutivos ou mais na tb_ddi. Um colaborador é considerado potencial a partir do terceiro mês consecutivo como usuário de dados.
- Excluir os colaboradores que atuam como Representantes da divisão de Shipping.

Importante: se você identificar outras ambiguidades, deve propor uma decisão e justificá-la.

Entregáveis

O que esperamos que você entregue:

- Um **documento ou apresentação em formato .pdf** que responda às perguntas presentes no desafio de acordo com o especificado no enunciado.

Para a sessão relacionada a *Visualização e Storytelling*, deve conter um mockup/wireframe que pode ser apresentado por meio de capturas adicionadas ao material ou, se preferir apresentá-lo em alguma ferramenta de visualização, deve haver um link.

IMPORTANTE: você receberá amostras de dados em formato CSV com informações fictícias para utilizar na construção do case. Os arquivos tb_people_history.csv e tb_ddi.csv contêm dados sintéticos do período janeiro–dezembro de 2025 com 800 colaboradores, 10 sites e 12 divisões.

Você pode e deve assumir premissas se necessário, desde que estejam declaradas e justificadas.

Instruções para a entrega

Você terá 3 dias úteis para resolver o desafio.
A resolução do case deve ser enviada para os e-mails alinea.oliveira@mercadolivre.com e natali.chavez@mercadolibre.com.co com o título [Case Analista de Dados] - Nome Sobrenome.

1. Produto, Métricas e Governança

1.1. Diagnóstico do estado atual

1.1.1. Quais decisões o dashboard atual não suporta bem / quais perguntas críticas ficam sem resposta?

Utilize os exemplos de dashboard fornecidos anteriormente.

1.2. Definições e dicionário de métricas

Crie um mini "metrics spec" com:

1.2.1. Universo e elegibilidade

- Universo base: colaboradores ativos
- Regras de exclusão: Representantes de Shipping
- Regras de abrangência: como tratar colaboradores ativos sem registro na tb_ddi durante o mês

1.2.2. Métricas

- **active_collaborators**
- **potential_users**
- **data_driven_users**
- **share_per_ddi_classification**: % de usuários potenciais por classificação de DDI
- **coverage_rate**: % do universo com registro na tb_ddi no mês
- **transition_rate**: migração entre classificações MoM (exemplo: Beginner → Intermediate)
- **gap_to_target**: diferença vs meta/benchmark (se não houver meta, proponha um benchmark interno: mediana do site/divisão)

1.2.3. Explique como você implementaria em SQL a regra de "3 meses consecutivos com is_data_user = True" para identificar os usuários potenciais.

2. Modelagem

2.1. Descreva seu design alvo para BI

2.1.1. Camadas e granularidade

- **User-month (silver):** um registro por username + date_month com atributos organizacionais "congelados" para o mês.

Explique como você resolve as mudanças de divisão/departamento ao longo do tempo.

- **Agg-month (gold):** agregações por date_month + site + divisão + departamento + user_classification.

2.2. Qualidade e Performance

2.2.1. Quais validações você executaria a cada mês para garantir que não haja duplicidade por user-month e classificações inválidas?

2.2.2. Quais práticas você utilizaria para garantir que o desempenho dos datasets seja eficiente e de baixo custo?

3. SQL

3.1. Criação de tabelas e métricas

3.1.1. Escreva uma query que gere uma tabela mensal agregada com as seguintes informações:

- date_month
- site
- division
- department
- user_classification

3.1.2. Escreva uma query que gere as métricas:

- active_collaborators
- potential_users
- data_driven_users
- share_per_ddi_classification

3.2. Conceituais

Responda em texto e adicione exemplos:

3.2.1. Explique a diferença entre as seguintes funções e inclua um exemplo usando tb_ddi, explicando o efeito dos valores nulos.

- COUNT(*)
- COUNT(coluna)
- COUNT(DISTINCT coluna)

3.2.2. Em um cenário com duplicidade (por exemplo, mais de uma linha por username + date_month), como isso afeta as métricas abaixo e como você detectaria e corrigiria esse problema?

- COUNT(*)
- COUNT(DISTINCT username)
- métricas de share por classificação

3.2.3. Explique, com exemplo, a diferença entre filtrar no WHERE e filtrar no ON em um LEFT JOIN.

3.2.4. Retorne o registro mais recente "Beginner" para todos os usuários (1 por usuário).

4. Visualização de dados e Storytelling

4.1. Crie um mockup/wireframe de um dashboard seguindo boas práticas de UX/data storytelling que possa responder com clareza e poucas interações as seguintes perguntas:

- Onde estamos? (níveis: empresa → site → divisão → departamento)
- O que mudou? (MoM e tendência 3M/6M/12M)
- Por que mudou? (quais divisões e classificações impulsionaram a variação)